

Discussion des résultats et des expérimentations — RL-in-GA pour le problème du sac à dos

RALAIVAO Niaiko Michaël — Master Recherche, ENI / LIMAD / GLoRIA

Septembre 2026

Table des matières

1	Retour sur les hypothèses	1
2	Interprétation	2
2.1	L'effet principal est la diversification des opérateurs, pas l'apprentissage en ligne .	2
2.2	L'apprentissage devient utile lorsqu'il est pré-entraîné et transféré	3
2.3	Les limites du transfert : le cas du MKP	3
2.4	Le descripteur d'instance n'aide pas (encore)	3
2.5	Pourquoi la récompense la plus simple est la meilleure	4
2.6	Positionnement face aux méthodes exactes	4
2.7	Un échec instructif : l'admission de machines virtuelles	4
3	Limites et menaces à la validité	4
4	Apports et leçons	5

1 Retour sur les hypothèses

Hypothèse	Énoncé	Verdict	Éléments décisifs
H1	L'AG piloté par AR fait mieux que l'AG standard	Confirmée	E1 : écart moyen 0,0074 % (pré-entraîné) et 0,0111 % (en ligne) contre 0,0382 %; $p < 10^{-10}$; aucune instance perdue. E2 : 0,0174 % contre 0,0407 % (p Holm = 0,001, 5/26/0). E3 (MKP) : 0,236 % contre 0,335 % ($p < 10^{-10}$, 28/30/0).
H2	En ligne, le QL ne dépasse pas une sélection aléatoire	Confirmée	E1 : 0,0111 % contre 0,0111 %, $p = 1,00$; choix d'actions quasi uniformes. Confirmé sur E2 ($p = 1,00$) et sur le MKP (E3, $p = 0,43$).

Hypothèse	Énoncé	Verdict	Éléments décisifs
H3	Une Q-table apprise sur des instances faciles se transfère et approche l'oracle	Partiellement confirmée (KP 0/1); non confirmée pour le transfert vers le MKP	E1 : meilleure que aléatoire, UCB1 et QL en ligne ($p \leq 0,003$, 0 défaite) mais inférieure à l'oracle (0/45/9). E2 : meilleure moyenne et meilleur rang, devant l'oracle (0,0174 % contre 0,0248 %), mais différences non significatives face aux autres adaptatifs. E3 (MKP) : aucun gain au-delà de la diversification — le transfert inter-problèmes n'est pas établi.
H4	Les méthodes exactes dominant sur le KP 0/1 modéré; l'AG + AR prend l'avantage quand la PD devient infaisable ou pour le MKP	Confirmée pour la première partie; nuancée pour la seconde	PD $\leq 3,4$ s sur E1; PLNE optimale sur tous les cas d'usage en < 2 s; PD infaisable pour $C = 10^8$ (Jooken). E2 : sur les instances de Jooken à $C = 10^8$, PD infaisable et PLNE non optimale en 60 s; toutes les variantes d'AG (≈ 7 s) font mieux . E3 : la PLNE (60 s) reste meilleure que l'AG (≈ 2 s) sur le MKP testé. E5 : PD hors de portée au-delà de 5 000 objets; PLNE sans preuve d'optimalité sur SC dès 500 objets; mais, à budget fixe, le glouton devient meilleur que l'AG au-delà de 5 000 objets.

2 Interprétation

2.1 L'effet principal est la diversification des opérateurs, pas l'apprentissage en ligne

Le résultat le plus robuste de ce travail est que **varier les opérateurs** au cours de la recherche — de quelque manière que ce soit — améliore fortement l'AG standard : sélection aléatoire, bandit UCB1 et Q-learning en ligne obtiennent des performances statistiquement indiscernables, toutes environ 3,5 fois meilleures que l'AG standard sur E1. La figure `fig04_politique_actions` en donne la raison, conforme à l'analyse du dilemme exploration–exploitation (SUTTON & BARTO, 2018) : en 200 générations, l'agent en ligne n'a vu chacun de ses 27×9 couples état–action qu'une poignée de fois; ses choix restent quasi uniformes, c'est-à-dire **équivalents au hasard**. Le bandit UCB1 (AUER et al., 2002) se comporte de même car les récompenses, très faibles et non stationnaires (elles décroissent au fil de la recherche), ne permettent pas à ses estimations de se séparer.

Cette observation rejoint un point connu de la littérature sur la sélection adaptative d’opérateurs : un portefeuille d’opérateurs *tous raisonnables* rend la sélection aléatoire difficile à battre, et le gain de l’apprentissage n’est mesurable que si des opérateurs sont nettement meilleurs que d’autres **et** si l’agent dispose d’assez d’interactions pour les identifier (DA COSTA et al., 2008; KARIMI-MAMAGHAN et al., 2022). Elle justifie a posteriori l’inclusion systématique d’un **témoin aléatoire** : sans lui, nous aurions conclu à tort que le Q-learning en ligne « améliore l’AG de 71 % » alors que cet effet est dû à la diversification. Plusieurs travaux hybrides AG–apprentissage par renforcement ne comparent leur méthode qu’à l’AG standard (CHEN et al., 2020; CUI & YUAN, 2024; PETTINGER & EVERSON, 2002); les revues récentes recommandent au contraire des témoins plus exigeants (LI et al., 2025; SONG et al., 2023).

2.2 L’apprentissage devient utile lorsqu’il est pré-entraîné et transféré

Le pré-entraînement lève la contrainte du nombre d’interactions, comme dans la configuration dynamique d’algorithmes apprise sur une distribution d’instances (BENJAMINS et al., 2024; BIEDENKAPP et al., 2020) : la Q-table **Q_OOD** a accumulé 9 600 pas de décision sur 12 instances faciles. Elle identifie la famille d’opérateurs la plus efficace (croisement uniforme avec mutation BF3 ou échange) — celle-là même que la calibration exhaustive des 9 configurations fixes désigne comme oracle — **sans l’avoir jamais « vue » sur des instances difficiles**, et la réutilise sur des classes (SC, ASC, ISC) et des tailles (500–1 000 objets) absentes de l’entraînement. C’est une confirmation, à l’échelle d’un master, de l’intuition du GAP 1 : *apprendre à chercher* (quels opérateurs utiliser selon l’état de la recherche) se transfère mieux qu’*apprendre à choisir* la solution, car cette connaissance dépend moins de la distribution des instances. Les approches de bout en bout, qui construisent directement la solution (BELLO et al., 2016; KOOL et al., 2019; KWON et al., 2020), doivent au contraire être réentraînées lorsque la distribution change (MAZYAVKINA et al., 2021; YOSHUA BENGIO et al., 2021).

L’écart résiduel avec l’oracle s’explique par deux défauts identifiés : (i) les états de milieu de recherche, peu visités pendant l’entraînement, ont des valeurs Q quasi nulles et l’agent y choisit presque au hasard; (ii) la récompense (amélioration relative du meilleur) s’éteint en fin de recherche, où les améliorations deviennent infimes, ce qui affaiblit l’apprentissage dans ces états — un problème d’attribution du crédit bien identifié en apprentissage par renforcement pour l’optimisation combinatoire (YAN et al., 2022).

2.3 Les limites du transfert : le cas du MKP

Appliquée sans modification au sac à dos multidimensionnel (CHU & BEASLEY, 1998; KELLERER et al., 2004), la Q-table apprise sur le KP 0/1 conserve l’avantage de la diversification (elle bat nettement l’AG standard) mais ne fait pas mieux que la sélection aléatoire, alors que l’oracle (croisement uniforme + BF3) reste significativement meilleur. Autrement dit, la **connaissance « quels opérateurs utiliser » se transfère d’une classe de KP à une autre et à des tailles supérieures, mais pas d’un problème à un autre** lorsque la structure des contraintes change : l’état observé par l’agent (diversité, stagnation, avancement) ne contient aucune information sur la structure multi-contraintes, et la dynamique de la recherche diffère. Un entraînement incluant des instances MKP, ou une représentation de l’instance (nombre de contraintes, serrage par dimension), comme dans les travaux dédiés au MKP (BUSHAJ & BÜYÜKTAHTAKIN, 2024; OZSOYDAN & GÖLCÜK, 2023), sont nécessaires — c’est le prolongement naturel de l’hypothèse H3 du GAP 1 (transfert KP → MKP).

2.4 Le descripteur d’instance n’aide pas (encore)

La variante avec descripteur $\varphi(I)$ (81 états) fait moins bien que la version sans descripteur (0,0105 % contre 0,0074 %). À budget d’entraînement comparable, tripler le nombre d’états dilue l’expérience de l’agent. Ce résultat négatif est instructif : l’information d’instance doit être **représentée**

de manière continue et généralisable (approximation de fonction, réseaux sur ensembles) plutôt que par un découpage discret, par exemple par des réseaux invariants par permutation (LEE et al., 2019) ou des réseaux de neurones sur graphes (KHALIL et al., 2017) — c’est exactement l’objet du GAP 3.

2.5 Pourquoi la récompense la plus simple est la meilleure

Lors de la calibration, ajouter le taux de descendants meilleurs que leurs parents a favorisé les opérateurs **prudents** (1P + BF1), qui produisent souvent des descendants légèrement meilleurs mais n’explorent pas : une récompense **myope** récompense l’exploitation immédiate au détriment de la qualité finale. La pénalité de perte de diversité, de son côté, pénalise toute la fin de recherche (où la diversité baisse inévitablement) et brouille le signal. L’amélioration relative du meilleur individu, bien que parcimonieuse, reste la mieux alignée avec l’objectif final, comme dans la plupart des schémas de sélection d’opérateurs par apprentissage par renforcement (KARIMI-MAMAGHAN et al., 2022; TALBI, 2021).

2.6 Positionnement face aux méthodes exactes

Sur le KP 0/1 de taille modérée, les méthodes exactes sont **imbattables** : la programmation dynamique (BELLMAN, 1957; KELLERER & PFERSCHY, 2004) résout les instances d’E1 en quelques secondes au plus, et la PLNE (solveur HiGHS (HUANGFU & HALL, 2018)) trouve l’optimum de toutes les instances d’E1 et de tous les cas d’usage, même lorsqu’elle ne parvient pas à *prouver* l’optimalité dans le temps imparti (12 instances corrélées). C’est cohérent avec le statut du KP 0/1, NP-difficile au sens faible (CACCHIANI et al., 2022; GAREY & JOHNSON, 1979; PISINGER, 2005). Les instances de JOOKEN et al. (2022) montrent toutefois qu’il existe des KP 0/1 difficiles pour les solveurs exacts. L’intérêt de l’AG + AR n’est donc pas de remplacer ces méthodes sur ce problème, mais de fournir un **cadre générique** (même code pour KP et MKP, sans modélisation mathématique ni solveur) et un outil qui reste applicable quand la PD devient infaisable (capacités de 10^8 chez Jookan). L’expérience E5 précise ce positionnement : à grande échelle, l’avantage ne revient pas automatiquement à l’AG — à budget fixe de 200 générations et avec une population initiale aléatoire, il est dépassé par le simple glouton à partir de 5 000 objets, tandis que le QL pré-entraîné reste 3 à 8 fois meilleur que l’AG standard. Un AG compétitif à cette échelle doit être **initialisé par le glouton** et disposer d’un budget adapté à la taille ; ce sont des améliorations d’ingénierie qui laissent intacte la conclusion principale (apport du pré-entraînement relativement à l’AG non piloté).

2.7 Un échec instructif : l’admission de machines virtuelles

Sur le cas d’usage « machines virtuelles » (MKP à 3 ressources, 300 demandes), l’AG standard obtient le meilleur écart moyen des variantes d’AG (2,3 %), devant le QL en ligne (2,8 %), le QL pré-entraîné (3,4 %) et l’aléatoire (4,0 %), tous loin de la PLNE (optimale en 1,5 s) ; le glouton y est très mauvais (25 %). Les objets y sont peu nombreux et très hétérogènes (8 profils, du « micro » au « stockage »), si bien que les opérateurs disruptifs (croisement uniforme) détruisent des combinaisons cohérentes. La politique transférée, apprise sur des KP 0/1 aux objets homogènes, **n’est pas universelle**, conformément au théorème « pas de repas gratuit » (WOLPERT & MACREADY, 1997) : c’est une limite directe de l’hypothèse de transfert, qui plaide pour un entraînement sur une distribution d’instances plus variée et pour une représentation de l’instance.

3 Limites et menaces à la validité

Validité interne. Graines appariées et identiques pour toutes les méthodes ; même budget d’évaluations ; calibration et entraînement sur des instances disjointes des tests. En revanche, l’oracle (UX + BF3) a été choisi sur des instances SC/ASC/UC de calibration : son avantage sur les autres classes peut être légèrement surestimé ou sous-estimé.

Validité de construction. L'écart à l'optimum est mesuré à budget d'évaluations fixe ; à **temps** égal, le classement pourrait différer légèrement (le QL coûte $\approx 10\%$ de temps en plus). Les écarts sont petits en valeur absolue (centièmes de %), car la réparation gloutonne rend l'AG déjà très bon ; les conclusions portent sur des différences relatives significatives.

Validité externe. Un seul AG, une seule réparation, un seul budget ($P = 100$, $G = 200$) et 10 exécutions par instance ; instances de 100 à 2 000 objets (10 000 pour E5) ; un seul type d'agent (Q-learning tabulaire). La généralisation à d'autres métaheuristiques, budgets et problèmes reste à établir (DOKEROGLU et al., 2024 ; RAJWAR et al., 2023).

Validité statistique. Tests non paramétriques appariés au niveau instance (Wilcoxon, Friedman) avec correction de Holm, selon DEMŠAR (2006) et DERRAC et al. (2011) ; tailles d'effet A_{12} (VARGHA & DELANEY, 2000) modérées (0,58–0,74). La différence critique de Nemenyi ($CD = 1,23$) ne sépare pas QL pré-entraîné et oracle au niveau des rangs, mais le test apparié de Wilcoxon, plus puissant, les distingue.

4 Apports et leçons

1. **Pour le praticien** : sur le KP/MKP, un AG avec réparation gloutonne et **diversité d'opérateurs** (même aléatoire) est un solide point de départ ; un réglage appris hors ligne améliore encore la qualité sans réglage manuel par classe (BIEDENKAPP et al., 2020 ; EIBEN et al., 1999).
2. **Pour le chercheur** : toute étude « RL-in-GA » devrait inclure des témoins **aléatoire, bandit et meilleure configuration fixe** ; sans eux, l'apport de l'apprentissage est surestimé.
3. **Pour la suite** : le transfert fonctionne quand la distribution d'entraînement couvre la structure des instances cibles, et échoue sinon (machines virtuelles) — la représentation de l'instance et de la population est la clé (voir `perspectives.md`).

Bibliographie

- AUER, P., CESA-BIANCHI, N., & FISCHER, P. (2002). Finite-time Analysis of the Multiarmed Bandit Problem. *Machine Learning*, 47(2–3), 235–256. <https://doi.org/10.1023/A:1013689704352>
- BELLMAN, R. (1957). *Dynamic Programming*. Princeton University Press.
- BELLO, I., PHAM, H., LE, Q. V., NOROUZI, M., & BENGIO, S. (2016). Neural Combinatorial Optimization with Reinforcement Learning.
- BENJAMINS, C., CENIKJ, G., NIKOLIKJ, A., MOHAN, A., EFTIMOV, T., & LINDAUER, M. (2024). Instance Selection for Dynamic Algorithm Configuration with Reinforcement Learning : Improving Generalization. *Proceedings of the Genetic and Evolutionary Computation Conference Companion (GECCO '24)*.
- BIEDENKAPP, A., BOZKURT, H. F., EIMER, T., HUTTER, F., & LINDAUER, M. (2020). Dynamic Algorithm Configuration : Foundation of a New Meta-Algorithmic Framework. *Proceedings of the 24th European Conference on Artificial Intelligence (ECAI 2020)*, 427–434. <https://doi.org/10.3233/FAIA200122>
- BUSHAJ, S., & BÜYÜKTAHTAKIN, İ. E. (2024). A K-means Supported Reinforcement Learning Framework to Multi-dimensional Knapsack. *J Glob Optim.* <https://doi.org/10.1007/s10898-024-01364-6>
- CACCHIANI, V., IORI, M., LOCATELLI, A., & MARTELLO, S. (2022). Knapsack problems — An overview of recent advances. Part I : Single knapsack problems. *Computers & Operations Research*, 143, 105692. <https://doi.org/10.1016/j.cor.2021.105692>
- CHEN, R., YANG, B., LI, S., & WANG, S. (2020). A self-learning genetic algorithm based on reinforcement learning for flexible job-shop scheduling problem. *Computers & Industrial Engineering*, 149, 106778. <https://doi.org/10.1016/j.cie.2020.106778>
- CHU, P. C., & BEASLEY, J. E. (1998). A Genetic Algorithm for the Multidimensional Knapsack Problem. *Journal of Heuristics*, 4(1), 63–86. <https://doi.org/10.1023/A:1009642405419>

- CUI, W., & YUAN, B. (2024). A hybrid genetic algorithm based on reinforcement learning for the energy-aware production scheduling in the photovoltaic glass industry. *Computers & Operations Research*, 163, 106521. <https://doi.org/10.1016/j.cor.2023.106521>
- DA COSTA, L., FIALHO, Á., SCHOENAUER, M., & SEBAG, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the 10th Annual Conference on Genetic and Evolutionary Computation (GECCO '08)*, 913-920. <https://doi.org/10.1145/1389095.1389272>
- DEMŠAR, J. (2006). Statistical Comparisons of Classifiers over Multiple Data Sets. *Journal of Machine Learning Research*, 7, 1-30.
- DERRAC, J., GARCÍA, S., MOLINA, D., & HERRERA, F. (2011). A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, 1(1), 3-18. <https://doi.org/10.1016/j.swevo.2011.02.002>
- DOKEROGLU, T., KUCUKYILMAZ, T., & TALBI, E.-G. (2024). Hyper-heuristics : A survey and taxonomy. *Computers & Industrial Engineering*, 187, 109815. <https://doi.org/10.1016/j.cie.2023.109815>
- EIBEN, Á. E., HINTERDING, R., & MICHALEWICZ, Z. (1999). Parameter control in evolutionary algorithms. *IEEE Transactions on Evolutionary Computation*, 3(2), 124-141. <https://doi.org/10.1109/4235.771166>
- GAREY, M. R., & JOHNSON, D. S. (1979). *Computers and Intractability : A Guide to the Theory of NP-Completeness*. W. H. Freeman.
- HUANGFU, Q., & HALL, J. A. J. (2018). Parallelizing the dual revised simplex method. *Mathematical Programming Computation*, 10(1), 119-142. <https://doi.org/10.1007/s12532-017-0130-5>
- JOOKEN, J., LEYMAN, P., & DE CAUSMAECKER, P. (2022). A new class of hard problem instances for the 0-1 knapsack problem. *European Journal of Operational Research*, 301(3), 841-854.
- KARIMI-MAMAGHAN, M., MOHAMMADI, M., MEYER, P., KARIMI-MAMAGHAN, A. M., & TALBI, E.-G. (2022). Machine learning at the service of meta-heuristics for solving combinatorial optimization problems : A state-of-the-art. *European Journal of Operational Research*, 296(2), 393-422. <https://doi.org/10.1016/j.ejor.2021.04.032>
- KELLERER, H., & PFERSCHY, U. (2004). Improved Dynamic Programming in Connection with an FPTAS for the Knapsack Problem. *Journal of Combinatorial Optimization*, 8(1), 5-11. <https://doi.org/10.1023/B:JOCO.0000021934.29833.6b>
- KELLERER, H., PFERSCHY, U., & PISINGER, D. (2004). Multidimensional Knapsack Problems. In H. KELLERER, U. PFERSCHY & D. PISINGER (Éd.), *Knapsack Problems* (p. 235-283). Springer. https://doi.org/10.1007/978-3-540-24777-7_9
- KHALIL, E., DAI, H., ZHANG, Y., DILKINA, B., & SONG, L. (2017). Learning Combinatorial Optimization Algorithms over Graphs. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 6348-6358.
- KOOL, W., van HOOF, H., & WELLING, M. (2019). Attention, Learn to Solve Routing Problems! *International Conference on Learning Representations (ICLR 2019)*.
- KWON, Y.-D., CHOO, J., KIM, B., YOON, I., GWON, Y., & MIN, S. (2020). POMO : Policy Optimization with Multiple Optima for Reinforcement Learning. *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 21188-21198.
- LEE, J., LEE, Y., KIM, J., KOSIOREK, A., CHOI, S., & TEH, Y. W. (2019). Set Transformer : A Framework for Attention-based Permutation-Invariant Neural Networks. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, 3744-3753.
- LI, P., HAO, J., TANG, H., FU, X., ZHENG, Y., & TANG, K. (2025). Bridging Evolutionary Algorithms and Reinforcement Learning : A Comprehensive Survey on Hybrid Algorithms. *IEEE Transactions on Evolutionary Computation*, 29(5), 1707-1728. <https://doi.org/10.1109/TEVC.2024.3443913>
- MAZYAVKINA, N., SVIRIDOV, S., IVANOV, S., & BURNAEV, E. (2021). Reinforcement learning for combinatorial optimization : A survey. *Computers & Operations Research*, 134, 105400. <https://doi.org/10.1016/j.cor.2021.105400>

- OZSOYDAN, F. B., & GÖLCÜK, İ. (2023). A reinforcement learning based computational intelligence approach for binary optimization problems : The case of the set-union knapsack problem. *Engineering Applications of Artificial Intelligence*, 118, 105688. <https://doi.org/10.1016/j.engappai.2022.105688>
- PETTINGER, J. E., & EVERSON, R. M. (2002). Controlling Genetic Algorithms With Reinforcement Learning. *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO 2002)*. <https://doi.org/10.5555/2955491.2955607>
- PISINGER, D. (2005). Where are the hard knapsack problems? *Computers & Operations Research*, 32(9), 2271-2284. <https://doi.org/10.1016/j.cor.2004.03.002>
- RAJWAR, K., DEEP, K., & DAS, S. (2023). An exhaustive review of the metaheuristic algorithms for search and optimization : taxonomy, applications, and open challenges. *ArtifIntell Rev*, 1-71. <https://doi.org/10.1007/s10462-023-10470-y>
- SONG, Y., WU, Y., GUO, Y., YAN, R., SUGANTHAN, P. N., ZHANG, Y., PEDRYCZ, W., CHEN, Y., DAS, S., MALLIPEDDI, R., & AJANI, O. S. (2023, août). Reinforcement Learning-assisted Evolutionary Algorithm : A Survey and Research Opportunities. <https://doi.org/10.48550/arXiv.2308.13420>
- SUTTON, R. S., & BARTO, A. G. (2018). *Reinforcement Learning : An Introduction* (2^e éd.). MIT Press.
- TALBI, E.-G. (2021). Machine Learning into Metaheuristics : A Survey and Taxonomy. *ACM Computing Surveys*, 54(6), 129 :1-129 :32. <https://doi.org/10.1145/3459664>
- VARGHA, A., & DELANEY, H. D. (2000). A Critique and Improvement of the CL Common Language Effect Size Statistics of McGraw and Wong. *Journal of Educational and Behavioral Statistics*, 25(2), 101-132. <https://doi.org/10.3102/10769986025002101>
- WOLPERT, D. H., & MACREADY, W. G. (1997). No Free Lunch Theorems for Optimization. *IEEE Transactions on Evolutionary Computation*, 1(1), 67-82. <https://doi.org/10.1109/4235.585893>
- YAN, D., WENG, J., HUANG, S., LI, C., ZHOU, Y., SU, H., & ZHU, J. (2022). Deep reinforcement learning with credit assignment for combinatorial optimization. *Pattern Recognition*, 124, 108466. <https://doi.org/10.1016/j.patcog.2021.108466>
- YOSHUA BENGIO, ANDREA LODI & ANTOINE PROUVOST. (2021). Machine learning for combinatorial optimization : A methodological tour d'horizon. *European Journal of Operational Research*, 290(2), 405-421. <https://doi.org/10.1016/j.ejor.2020.07.063>