

Perspectives de recherche — RL-in-GA pour le problème du sac à dos et au-delà

RALAIVAO Niaiko Michaël — Master Recherche, ENI / LIMAD / GLORIA

Septembre 2026

Table des matières

1	Ce qui manque au travail actuel (limites à lever en priorité)	1
2	Extensions méthodologiques	2
3	Autres variantes du sac à dos et autres problèmes	3
4	Interactions avec d'autres domaines	3
5	Feuille de route proposée (vers une thèse)	3

Ce document recense ce qui **manque** au travail actuel, les **extensions** immédiates, les **interactions avec d'autres domaines** et les pistes de **généralisation**. Les pistes sont classées par horizon (court : quelques semaines ; moyen : un semestre ; long : une thèse).

1 Ce qui manque au travail actuel (limites à lever en priorité)

Limite	Conséquence	Action proposée	Horizon
Population initiale aléatoire et budget indépendant de n	Au-delà de 5 000 objets, le glouton bat l'AG (E5)	Initialisation gloutonne d'une fraction de la population (option <code>init_greedy_fraction</code> déjà codée) ; budget proportionnel à n	court
Budget d'évaluation unique ($P = 100$, $G = 200$)	Les conclusions peuvent dépendre du budget : avec plus de générations, le QL en ligne aurait plus de temps pour apprendre	Courbes « qualité vs budget » ($G \in \{50, 100, 200, 500, 1\,000\}$) ; comparaison à temps de calcul égal	court
Une seule métaheuristique de base et une seule réparation (très efficace)	La réparation gloutonne « lisse » les différences entre opérateurs	Répéter avec pénalisation au lieu de réparation ; faire de la stratégie de réparation une action ($GAP\ 1$, action r_t)	court

Limite	Conséquence	Action proposée	Horizon
Signal de récompense qui s'éteint en fin de recherche	Les états « fin de recherche » sont peu ou pas appris ($Q \approx 0$)	Récompenses normalisées par rang ou relatives aux améliorations récentes; attribution de crédit par valeurs extrêmes (EVCA) ou fenêtre glissante (KARIMI-MAMAGHAN et al., 2022)	court
Espace d'état discret et grossier (27 états)	Généralisation limitée; seuils calibrés à la main	Q-learning avec approximation de fonction (tuile, MLP); DQN (MNIH et al., 2015) ou PPO (SCHULMAN et al., 2017) sur l'état continu	moyen
Descripteur d'instance $\varphi(I)$ scalaire	Les états « classe difficile » ne sont vus qu'à l'entraînement	Représentation apprise de l'instance et de la population : Deep Sets / Set Transformer (LEE et al., 2019) sur les objets (w_i, v_i, p_i) (GAP 3)	moyen
10 exécutions par instance, instances de taille $\leq 2\,000$ (sauf E5)	Puissance statistique limitée sur les petites différences	30 exécutions; instances de Pisinger « hard » (déjà téléchargées) et 3 240 instances de Jookan	court
Comparaison exacte limitée à la PD et à HiGHS	Pas de comparaison avec <i>Combo</i> ou <i>Expknapp</i>	Intégrer <i>Combo</i> (code C de Pisinger) comme référence exacte spécialisée	court

2 Extensions méthodologiques

1. **Contrôle continu des paramètres** : au lieu de 9 actions discrètes, l'agent règle directement (p_c, p_m, k) — politique continue (PPO, SAC) ; comparaison avec la configuration dynamique d'algorithmes (BIEDENKAPP et al., 2020).
2. **Méta-apprentissage et transfert systématique** : entraîner sur une distribution hétérogène d'instances et mesurer la généralisation hors distribution selon trois axes — taille, corrélation, serrage — comme proposé dans l'hypothèse GAP 1 ; sélection d'instances d'entraînement représentatives (BENJAMINS et al., 2024).
3. **Portefeuille de politiques (GAP 2)** : une archive MAP-Elites (MOURET & CLUNE, 2015) indexée par les caractéristiques d'instance (corrélation $\times$ serrage) contenant des politiques spécialisées, sélectionnées à l'exécution.
4. **Boucle fermée AR $\leftrightarrow$ AG (type EAM)** : une politique neuronale constructive initialise la population et l'AG affine ; les solutions évoluées ré-entraînent la politique (GU et al., 2025) — à étendre au KP et à l'évaluation hors distribution.
5. **Hyper-heuristique** : l'agent choisit entre heuristiques complètes (AG, recuit simulé, recherche tabou, recherche locale) plutôt qu'entre opérateurs (DOKEROGLU et al., 2024; KALLESTAD et al., 2023).
6. **Cadre théorique** : relier la diversité de population (ou l'entropie des fréquences p_i) à la capacité de généralisation (question QT1/QT4 du brainstorming) ; borne sur le biais introduit par l'agent (à la manière de la borne KL d'EAM).

3 Autres variantes du sac à dos et autres problèmes

Cible	Ce qui change	Intérêt
MKP de grande taille (GK, OR30x500)	rien dans l'architecture	NP-difficile au sens fort : la PLNE atteint vite ses limites
Sac à dos avec graphe de conflits (KPCG) (PFERSCHY & SCHAUER, 2009), avec précédences (PCKP)	réparation respectant les conflits / précédences	lien avec la théorie des graphes et la coloration
Sac à dos quadratique, multiple, avec <i>setups</i> (CACCHIANI et al., 2022)	évaluation non linéaire, codage entier	variantes sans algorithme dédié performant
KP stochastique, dynamique, <i>chance-constrained</i>	l'état inclut l'incertitude ; ré-optimisation	logistique en temps réel
KP multi-objectif (valeur vs risque)	NSGA-II (DEB et al., 2002) piloté par AR	aide à la décision multicritère (axe du LIMAD)
TSP / CVRP, ordonnancement (FJSP)	codage en permutation, opérateurs OX / 2-opt	valider la généralité du cadre (GAP 1, cas TSP) (CHEN et al., 2020)

4 Interactions avec d'autres domaines

- **Aide à la décision territoriale et SIG** (LIMAD) : sélection de sites d'équipements, planification de projets communaux géolocalisés — prolongement direct de la communication de mai 2024 (cartographie numérique).
- **Logistique humanitaire** (gestion des risques et catastrophes) : chargement multi-contraintes, affectation de véhicules, avec données réelles d'organismes partenaires.
- **Infonuagique et réseaux** : placement de machines virtuelles, allocation de bande passante — problèmes MKP dynamiques.
- **Finance** : portefeuilles sous contraintes (KP moyenne-VaR (VAEZI et al., 2020)).
- **Génie logiciel** (équipe GLORIA) : sélection de fonctionnalités à livrer sous contrainte de budget (*next release problem*, variante du KP), sélection de tests de régression, allocation de ressources dans les projets agiles.
- **Modèles de langage** : génération ou sélection d'opérateurs par un LLM, avec l'AR pour arbitrer — piste émergente.

5 Feuille de route proposée (vers une thèse)

Phase	Contenu	Valorisation visée
1 (3 mois)	Levée des limites courtes : budget, réparation comme action, récompense normalisée, 30 exécutions, instances <i>hard</i>	article de conférence (CARI, GECCO <i>student workshop</i>)
2 (6 mois)	État continu + DQN/PPO ; représentation Set Transformer ; protocole OOD complet (taille × corrélation × serrage)	article (EvoCOP, LION)
3 (6–12 mois)	Généralisation TSP/FJSP ; portefeuille de politiques ; cas réels avec partenaires	revue (C&OR, EJOR, <i>Applied Soft Computing</i>)

Bibliographie

- BENJAMINS, C., CENIKJ, G., NIKOLIKJ, A., MOHAN, A., EFTIMOV, T., & LINDAUER, M. (2024). Instance Selection for Dynamic Algorithm Configuration with Reinforcement Learning : Improving Generalization. *Proceedings of the Genetic and Evolutionary Computation Conference Companion (GECCO '24)*.
- BIEDENKAPP, A., BOZKURT, H. F., EIMER, T., HUTTER, F., & LINDAUER, M. (2020). Dynamic Algorithm Configuration : Foundation of a New Meta-Algorithmic Framework. *Proceedings of the 24th European Conference on Artificial Intelligence (ECAI 2020)*, 427-434. <https://doi.org/10.3233/FAIA200122>
- CACCHIANI, V., IORI, M., LOCATELLI, A., & MARTELLO, S. (2022). Knapsack problems — An overview of recent advances. Part II : Multiple, multidimensional, and quadratic knapsack problems. *Computers & Operations Research*, 143, 105693. <https://doi.org/10.1016/j.cor.2021.105693>
- CHEN, R., YANG, B., LI, S., & WANG, S. (2020). A self-learning genetic algorithm based on reinforcement learning for flexible job-shop scheduling problem. *Computers & Industrial Engineering*, 149, 106778. <https://doi.org/10.1016/j.cie.2020.106778>
- DEB, K., PRATAP, A., AGARWAL, S., & MEYARIVAN, T. (2002). A fast and elitist multiobjective genetic algorithm : NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2), 182-197. <https://doi.org/10.1109/4235.996017>
- DOKEROGLU, T., KUCUKYILMAZ, T., & TALBI, E.-G. (2024). Hyper-heuristics : A survey and taxonomy. *Computers & Industrial Engineering*, 187, 109815. <https://doi.org/10.1016/j.cie.2023.109815>
- GU, S., LI, K., XING, J., ZHANG, Y., & CHENG, J. (2025). Synergizing Reinforcement Learning and Genetic Algorithms for Neural Combinatorial Optimization. <https://doi.org/10.48550/arXiv.2506.09404>
- KALLESTAD, J., HASIBI, R., HEMMATI, A., & SÖRENSEN, K. (2023). A general deep reinforcement learning hyperheuristic framework for solving combinatorial optimization problems. *European Journal of Operational Research*, 309(1), 446-468. <https://doi.org/10.1016/j.ejor.2023.01.017>
- KARIMI-MAMAGHAN, M., MOHAMMADI, M., MEYER, P., KARIMI-MAMAGHAN, A. M., & TALBI, E.-G. (2022). Machine learning at the service of meta-heuristics for solving combinatorial optimization problems : A state-of-the-art. *European Journal of Operational Research*, 296(2), 393-422. <https://doi.org/10.1016/j.ejor.2021.04.032>
- LEE, J., LEE, Y., KIM, J., KOSIOREK, A., CHOI, S., & TEH, Y. W. (2019). Set Transformer : A Framework for Attention-based Permutation-Invariant Neural Networks. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, 3744-3753.
- MNIH, V., KAVUKCUOGLU, K., SILVER, D., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533. <https://doi.org/10.1038/nature14236>
- MOURET, J.-B., & CLUNE, J. (2015). Illuminating search spaces by mapping elites. *arXiv preprint*.
- PFFERSCHY, U., & SCHAUER, J. (2009). The Knapsack Problem with Conflict Graphs. *JGAA*, 13(2), 233-249. <https://doi.org/10.7155/jgaa.00186>
- SCHULMAN, J., WOLSKI, F., DHARIWAL, P., RADFORD, A., & KLIMOV, O. (2017). Proximal Policy Optimization Algorithms.
- VAEZI, F., sadjadi seyed jafar , s. j., & MAKUL, A. (2020). Mean-VaR Portfolio Optimization Based on the Improved Knapsack Problem : Parametric and Nonparametric Approaches. *IJES*, 9(2). <https://doi.org/10.22099/ijes.2021.38133.1695>